

方案汇报 · 多模型协作 · 可审计标签

Sure-Tagger 多说话人证据协作 Pipeline

基于异构小模型证据交叉验证的 utterance-level 数据打标方案

1 个
utterance

固定输入粒度

4 类证据

事件 · 身份 · 覆盖 · 文本歧义

3 个标签

逐 claim 独立认证

H1/H2/H3

假设驱动冲突消解

版本：汇报版 · 2026-08-11

输入契约：sample.audio.path（整份文件即当前 utterance）

公开输出：multi_speaker / speaker_overlap / speaker_change

输入固定为 utterance-level sample；只读取 sample.audio.path；证据不足即 abstain。

目录

Sure-Tagger 多说话人证据协作 Pipeline（汇报版） 3

1. 核心思路3
2. Pipeline4
3. 哪些证据形成交叉验证5
4. Text 如何参与交叉验证5
5. 一个交叉验证示例6
6. 用假设 - 预测 - 检验消解冲突6
7. 冲突处理与输出7
8. 推荐落地顺序8

Sure-Tagger 多说话人证据协作 Pipeline (汇报版)

日期：2026-08-11

目标：为 utterance 生成 `speaker.multi_speaker`、`speaker.speaker_overlap`、`speaker.speaker_change`，证据不足时输出 `null`。


输入约束：保持现有 utterance-level `sample` 不变。`sample.audio` 只使用现有的 `path` 字段，整份文件就是当前 utterance。所有工具只处理这份音频，不拼接其它 sample，不向 recording 级扩展。

1. 核心思路

旧方案是“选择一个模型生成 timeline，再由同一 timeline 派生全部标签”。新方案参考 AUDIO-MIND，改成“多个小模型分工取证，按标签融合证据”：

- MOSS 和 pyannote 独立观察底层 speaker event。
- CAM++ 判断两个干净片段是否为不同 speaker。
- Silero VAD 检查语音覆盖和边界质量。
- Paraformer/Whisper 提供独立文本及时间线，检查漏检、边界歧义、backchannel 和串音。
- 发生冲突时先构造 claim-local 的 `H1/H2/H3` 假设，推导可证伪预测，再按区分能力调用 Sortformer、当前 sample 音频内的物理通道或 separation 等额外工具。
- 不做简单多数投票；先认证底层事件，再确定性生成公开标签。

2. Pipeline



实际执行分六步：

1. 直接读取现有 utterance-level `sample.audio.path`；不增加 `start_sec/end_sec` 等 input 字段，也不获取相邻 utterance。
2. 对同一份 `sample.audio` 并行生成 MOSS、pyannote、Silero 和独立 ASR 证据。
3. 把所有时间统一为相对当前 sample 音频起点的 `[0, duration_sec]`，只在 sample 内对齐匿名 speaker ID 和 lexical units。
4. 分别解析 `multi_speaker`、`speaker_overlap`、`speaker_change`，不共享一个总置信度。

- 对具体 claim 和局部事件构造“来源 A 的局部解释正确、来源 B 的局部解释正确、双方都不完整”分支；先冻结可证伪预测，再选择不继承冲突来源的独立工具检验。
- 分支排除后重新进入正常 resolver；仍无法区分，或剩余分支未达到原有认证门槛，则 abstain，公开值为 `null`。

3. 哪些证据形成交叉验证

交叉验证不是“模型数量”，而是不同证据角色共同满足一个 claim。

证据角色	默认来源	回答的问题	是否算底层事件票
<code>event_vote</code>	MOSS、pyannote；冲突时可用 Sortformer/当前 sample 音频内的物理通道	同一时间是否发生第二 speaker、overlap 或 floor transfer	是
<code>identity_guard</code>	CAM++；可选 ECAPA/可信物理映射	候选 A、B 是否确实为不同 speaker	否，只验证身份条件
<code>coverage_guard</code>	Silero VAD	scope 是否被完整检查，speech union 和边界是否可信	否，只验证覆盖条件
<code>ambiguity/review_guard</code>	Paraformer/Whisper speaker-text track	是否存在 lexical 空洞、跨边界 token、backchannel 或串音风险	否，只能阻止误认证或触发复核

三类公开标签的认证关系如下：

标签	主要交叉验证	认证重点
<code>multi_speaker=true</code>	MOSS speaker activity + pyannote speaker activity + CAM++	两条 timeline 都发现 material 第二 speaker，CAM++ 支持两段来自不同人
<code>speaker_overlap=true</code>	两条 overlap-capable timeline + CAM++ + Silero	两个模型必须在同一时间区域发现双人 activity；比较 event IoU、绝对时长和统一分母 ratio
<code>speaker_change=true</code>	两条 timeline 的 canonical A -> B floor transfer + CAM++	change point 在 collar 内匹配，边界两侧均有干净语音且 A/B 不同；不能把短 backchannel 当换人
三个标签的 <code>false</code>	两条通过本域负例校准的完整来源 + coverage guard	“没有检测到”不等于 false；必须校准模型组合的联合漏检风险

以下情况看似一致，但不算独立交叉验证：

- 同一 timeline 派生出的 `segments -> speakers -> summary -> bool`。
- MOSS diarization 与 MOSS transcript，因为二者来自同一次 joint generation。
- 同一 Whisper checkpoint 的不同 runtime/参数，或同一份 words 投影到多个 timeline。
- separation 生成两个 stem；它只是输入变换，必须回到原音频并由其它模型验证。

4. Text 如何参与交叉验证

只有 MOSS 原生输出 `speaker + segment text + timestamp`。Paraformer、Whisper、SenseVoice 本身没有 speaker ID，需要与 diarizer timeline 组合。

默认构造两条 speaker-text track：

```
MOSS joint track
= MOSS native speaker segment + text + time

independent ASR x pyannote track
= Paraformer CIF token interval 或 Whisper word interval
x pyannote speaker activity
```

二者可以检查：

- **lexical_presence**：ASR 有词但 VAD/diarizer 标为 silence，提示可能漏 speech。
- **boundary_ambiguity**：高质量 token 横跨候选 change/gap，阻止自动认证并触发重跑。
- **backchannel**：短“嗯/对/yeah”与短时第二 speaker onset 同时出现时，要求重查 floor state。
- **crosstalk**：当前 **sample.audio.path** 文件内的多个物理通道出现近同步相同文本时，结合能量、延迟和 embedding 排查串音。
- **assignment disagreement**：MOSS 与 ASR x pyannote 的 speaker-text 分配差异，可暴露 merge/split 问题。

Text 的边界必须明确：

- ASR 没有转出第二路文字，不能认证 **multi_speaker=false** 或 **speaker_overlap=false**。
- ASR x pyannote 的 speaker assignment 来自 pyannote，不能反过来作为 pyannote change 的新票。
- SenseVoiceSmall 有文本能力，但没有稳定词级时间，只作为第三份 lexical observation。
- 同一份 Whisper words 投影到多个 timeline，仍只有一个 Whisper evidence group。

5. 一个交叉验证示例

假设候选区间 **12.20-12.45 s**：

来源	观察
MOSS	A 与 B 在 12.20-12.42 s 同时 active
pyannote	X 与 Y 在 12.18-12.45 s 同时 active
CAM++	A/X 对齐、B/Y 对齐，A 与 B 为不同 speaker
Silero	scope speech coverage 完整，可计算统一 speech-union 分母

两条独立 timeline 的 overlap 区域高度重合，CAM++ 排除了同一人串音，Silero 提供可靠分母，因此可以认证 **speaker_overlap=true**。

如果 MOSS 和 pyannote 都输出 **true**，但标出的 overlap 区域完全不同，则不能认证；应调用 Sortformer 或当前 sample 音频内已有的物理通道检查，仍冲突则输出 **null**。ASR 只转出一路文本不影响这一判断。

6. 用假设 - 预测 - 检验消解冲突

冲突不直接做二选一。系统对具体 claim 和局部时间区域保存至少三个分支，并让每个分支对独立可观测测量作出预测；假设不是“MOSS 整条链路正确”这类全局判断：

```

H1 : 来源 A 对该局部事件的解释成立
H2 : 来源 B 对该局部事件的解释成立
H3 / H_other : 双方都不完整、都错, 或遗漏了第三种故障
    |
    v
生成并冻结 prediction + falsifier + dependency groups
    |
    v
调用最能区分分支的独立工具

```

例如 MOSS 判断 A/B 两人、pyannote 只判断 X 一人：

假设	如果正确, 应观察到什么	优先检验
H1: two-speaker event	A/B 的干净片段 embedding 不同, 第二人候选区有独立 activity	CAM++ ; 适用的 Sortformer/物理通道
H2: one-speaker event	MOSS A/B embedding 高度相似, 没有独立双人事件	CAM++ ; 第二 timeline/物理证据
H3: other/incomplete	H1/H2 的预测都失败, 或出现噪声、混响、背景声等未解释证据	新故障分类或人工复核

判定边界必须保守：

- 由 pyannote 派生的 speaker-text assignment 不能反过来证明 pyannote 正确；共享依赖的结果只能作 diagnostic。
- prediction 和 falsifier 必须在调用额外工具前冻结；不能看到结果后修改假设。
- 一个分支被反驳，不代表另一个分支自动正确；剩余分支仍需满足 event、identity、coverage 和校准门槛。
- “暂时没有发现矛盾”只表示分支仍可行，不等于得到正向支持。
- false 分支即使存活，也必须通过完整覆盖和模型组合的联合漏检校准。

该机制主要用于排除不可能解释、选择下一项高信息量证据和生成可审计的冲突说明，不能单独产出 **certified**。

7. 冲突处理与输出

每个 claim 使用四种状态：

状态	含义	公开输出
certified	event、identity、coverage、校准和冲突检查全部通过	bool
supported	有单边支持，但缺少独立证据或校准	null
conflicted	合格来源对值或事件位置仍有冲突	null，定向取证/人工复核
insufficient	输入、上下文、适用性或质量不足	null

所有 evidence 保存模型版本、能力、时间范围、输入 lineage 和依赖组。相同 checkpoint、同一 pipeline 的派生字段或共享上游的复合结果不得重复计票。

recording_id 不是 raw input 新字段：只能从已有 **sample.native_metadata** 复制为可选 opaque provenance，缺失时内部兼容 metadata 使用 **sample_id**。它不能作为 artifact join key，也不能用来读取、拼接或借用其它 utterance 的音频、speaker ID、embedding 或 transcript。短 sample 内没有足够 clean speech/context 时，对应 claim 返回 **insufficient/null**。

8. 推荐落地顺序

Phase 1 最小闭环：

- MOSS + pyannote Community-1 + Silero + CAM++。
- 中文/中英使用 Paraformer-zh，多语使用 Whisper base。
- 实现 timebase、speaker alignment、speaker-text track、三个 rule-based resolver，以及 speaker count/overlap/change 三类确定性 H1/H2/H3 冲突模板。
- public 只发布 `certified`，其它状态统一映射为 `null`。

Phase 2 冲突取证：

- 接入 Streaming Sortformer、当前 sample 音频内已有的物理通道、SenseVoice 第三观察和 targeted rerun；按预测区分能力选择下一项工具，而不是固定顺序全跑。
- 按语言、layout、speaker count、overlap ratio 校准模型组合。
- 用 risk-coverage curve 评估“高精度认证覆盖率”，而不是只看总体 accuracy。

上线前还需确认：标签语义版本、负例联合校准、模型许可，以及内部 transcript 的 PII/retention 策略。

详细规则、artifact schema、failure injection 和模型调研见 [evidence_fusion_design.md](#)。当前 metadata 定义见 [speaker_metadata_standard.md](#)。